

DATA VISUALIZATION

TEAM PROJECT

FINAL PRESENT

114421028 蔣宗勳

114421029 林苡嘉

114421046 柯劭潔

模型資料集和變數

資料集

- 以2020-2022年資料來進行RFM分析，將銷售資料和通話紀錄資料，透過會員編號(member_id)進行合併
- 以80%訓練，20%測試
- 694 個欄位

目標變數Y

- 0 (Loyal / 忠誠)：維持正常消費與高互動率。
- 1 (Partial Churn / 部分流失)：消費頻率或通話互動出現衰退。
- 2 (Churn / 完全流失)：長期無消費且無法聯絡。

模型訓練特徵說明

Type	Feature	Description
購買行為	Recency_Purchase_Days (距離最後一次購買過幾天)	距離最後一次購買的天數資料集最後一天日期 – 最後一次購買日期
	Purchase_count (購買次數)	總成交訂單次數
	Total Spend (總花費金額)	總消費金額
通話行為	Recency_Call_Days (距離最後一次通話過幾天)	距離最後一次通話的天數資料集最後一天日期 – 最後一次撥打電話日期
	Call_Count (撥打電話次數)	總通話次數，代表互動密度
	Avg_call_time (平均通話時間)	平均每通電話聊多久
	Pickup_Rate (接聽率)	電話有接起來的比例
	Unreachable_Rate (未聯絡上的比例)	找不到人（沒聯絡上）的比例

衍生特徵

滾動平均時序特徵 (roll3 / roll6)

同樣 6 種指標，各有 3 個月和 6 個月滾動平均版本，共 432 欄：

- m_spend_roll3_YYYY-MM：近3個月消費滾動平均
- m_spend_roll6_YYYY-MM：近6個月消費滾動平均
- 其他指標以此類推


滾動平均時序特徵 (roll3 / roll6)

每種指標萃取出 36 欄共 6 個時序統計值：


- _trend_slope：趨勢斜率（線性迴歸）
- _roc3：近3期變化率（Rate of Change）
- _std：標準差（波動程度）
- _ema_last：指數移動平均最後值
- _active_months：活躍月份數
- _months_since_active：距最後活躍月份數

資料不平衡 - SMOTE

Before SMOTE



After SMOTE



參數設定

超參數	值
objective	multi:softprob
eval_metric	mlogloss
n_estimators	500
learning_rate	0.05
max_depth	5
min_child_weight	7

資料不平衡

- 使用SMOTE進行處理

```
sm = SMOTE(random_state=42)
X_train_res, y_train_res = sm.fit_resample(X_train, y_train)
```

設定分類門檻

- 若 $P(\text{Class 2}) > t2 \rightarrow$ 判定為完全流失
- 若 $P(\text{Class 1}) > t1 \rightarrow$ 判定為部分流失
- 其餘 $\rightarrow$ 判定為忠實客戶

```
# t2 = class 2 門檻
# t1 = class 1 門檻
for t2 in np.arange(0.20, 0.51, 0.02): # 0.20 ~ 0.50
    for t1 in np.arange(0.20, t2, 0.02): # class1 門檻必須 < class2
        y_temp = []
        for p in proba:
            if p[2] > t2:
                y_temp.append(2)
            elif p[1] > t1:
                y_temp.append(1)
            else:
                y_temp.append(0)

        macro_f1 = f1_score(y_test, y_temp, average='macro')

        if macro_f1 > best_f1:
            best_f1 = macro_f1
            best_t1 = t1
            best_t2 = t2
            best_pred = y_temp
```

XGBoost加入LSTM混合模型

```
16/16 0s 4ms/step
===== 混合模型預測結果 =====
precision recall f1-score support
0 0.78 0.91 0.84 291
1 0.51 0.43 0.47 126
2 0.62 0.37 0.46 65
accuracy 0.71 482
macro avg 0.64 0.57 0.59 482
weighted avg 0.69 0.71 0.69 482
```

成效不佳的原因

- LSTM 沒有學到有效的時序資訊：LSTM 理論上擅長捕捉長期時序依賴，但我們的資料是月份級別、每人36筆，序列不夠長、資料量可能也不夠多，LSTM 很難真正收斂到有意義的表示，反而引入了噪音。
- 混合模型的特徵融合方式可能稀釋了 XGBoost 的優勢：XGBoost 本身已經能透過 roll3、roll6、trend_slope 這些手工時序特徵很好地掌握時間趨勢。再把 LSTM 的輸出疊進去後，如果 LSTM 輸出品質不好，反而是在加入雜訊，不是在補充資訊。
- 資料集本身對樹模型更友善：資料是寬表結構（694欄），有大量手工 feature engineering，這種格式天生就是為樹模型設計的。LSTM 偏好的是原始序列輸入，不是這種已經展開的寬表。

XGBoost預測結果

經實驗比較，混合模型（LSTM+XGBoost）在本資料集上的表現未優於單一模型。考量資料已包含完整的手工時序特徵，且樹模型對此類寬表結構具有天然優勢，最終選擇以 XGBoost 作為最終模型，在模型簡潔性與預測效能之間取得最佳平衡。


```
🚀 正在訓練 XGBoost 模型...
訓練完成！

===== 最佳 Threshold =====
最佳 class2 門檻 t2 = 0.42
最佳 class1 門檻 t1 = 0.38
最佳 Macro F1 = 0.6742

===== 最佳 Threshold 的預測結果 =====
Accuracy: 0.7323651452282157

```

	precision	recall	f1-score	support
0	0.84	0.83	0.83	283
1	0.56	0.61	0.58	133
2	0.66	0.56	0.61	66
accuracy			0.73	482
macro avg	0.69	0.67	0.67	482
weighted avg	0.74	0.73	0.73	482



THANK YOU !