

Team Project

114421028 蔣宗勳
114421029 林苡嘉
114421046 柯劭潔

```
from xgboost import XGBClassifier
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, f1_score

model_data = pd.read_csv('model_data.csv')

# 重新定義 X, y (使用你提供的 model_data.csv 特徵邏輯)
features = [
    'recency_purchase_days', 'purchase_count', 'total_spend',
    'recency_call_days', 'call_count', 'avg_call_time',
    'pickup_rate', 'unreachable_rate'
]
X = model_data[features]
y = model_data['target']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 調整模型參數以提高表現
model = XGBClassifier(
    n_estimators=200,      # 增加樹的數量
    learning_rate=0.05,    # 降低學習率讓模型學得更細緻
    max_depth=5,           # 限制深度防止過擬合
    subsample=0.8,         # 每次用 80% 資料隨機訓練，增加泛化能力
    colsample_bytree=0.8,
    scale_pos_weight=(len(y)-y.sum())/y.sum(),
    eval_metric='auc'      # 以 AUC 作為優化指標
)

model.fit(X_train, y_train)
```

處理資料不平衡
使用預設參數防止過擬合
以 AUC (ROC 曲線下面積) 作為主要優化指標

```
# 取得教師模型 (XGBoost) 對訓練集的預測機率
```

```
teacher_train_probs = model.predict_proba(X_train)[:, 1]
```

```
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor
```

```
from sklearn.metrics import roc_auc_score
```

```
# --- 實驗 A：一般學生（直接學習原始標籤 0/1） ---
```

```
# 使用 Classifier，因為目標是類別
```

```
student_simple = DecisionTreeClassifier(max_depth=5, random_state=42)
```

```
student_simple.fit(X_train, y_train)
```

```
# --- 實驗 B：蒸餾學生（學習教師的預測機率） ---
```

```
# 使用 Regressor，因為教師給的機率是連續數值 (0.0 ~ 1.0)
```

```
student_distilled = DecisionTreeRegressor(max_depth=5, random_state=42)
```

```
student_distilled.fit(X_train, teacher_train_probs)
```

【教師模型 XGBoost】	AUC: 0.7306
【一般學生 DecisionTree】	AUC: 0.6785
【蒸餾學生 DecisionTree】	AUC: 0.6552

教師：XGBOOST 模型
學生：DECISION TREE